「析数启智」时序多变量教育数据可视分析

——《数据可视化》课程期末项目文档

组名："视不可挡"队　小组成员：赵宇哲(2411094)、袁煜杰(2412303)、王奕瑜(2414007)

一、数据集介绍

1.1 原始数据集介绍

本项目使用的原始数据来源于第十一届中国可视化与可视分析大会（ChinaVis 2024）数据可视化竞赛"「析数启智」时序多变量教育数据可视分析挑战赛"中提供的数据集。该数据集提供了 15 个班级从 2023 年 8 月 31 日到 2024 年 1 月 25 日共 148 天的学习行为模拟数据，包括学习者基本信息（共 1364 名）、题目基本信息（共 44 条）和学习者答题行为日志记录（共 232818 条），均以 csv 格式给出。

Data_StudentInfo.csv 中展示了学习者的基本信息，相关字段名称和含义见表 1。

Data_TitleInfo.csv 中展示了题库题目的基本信息，相关字段名称和含义见表 2。

表 1　Data_StudentInfo.csv 字段解释

字段名称	字段含义	相关说明
index	学习者索引	
student_ID	学习者编号	唯一编码
sex	性别	
age	年龄	
major	专业	

表 2　Data_TitleInfo.csv 字段解释

字段名称	字段含义	相关说明
index	题目索引	
title_ID	题目编号	唯一编码
score	题目分数	
knowledge	知识点	题目可能考察多个知识点
sub_knowledge	从属知识点	知识点可能存在多个从属知识点

Data_SubmitRecord 文件夹中共包含 15 个班级（Class1~Class15）的学习者答题行为日志记录数据文件，以 SubmitRecord-Class1.csv 为例，相关字段名称和含义见表 3。

表 3　SubmitRecord-Class1.csv 字段解释

字段名称	字段含义	相关说明
index	记录索引	
class	班级	
time	日志生成时间	时间戳，精确到秒
state	答题状态	例如完全正确、部分正确等，共 12 种情况
score	答题分数	通过测试用例获得的分数
title_ID	题目编号	引用题目基本信息表中的 title_ID
method	语言	学习者答题采用的编程语言
memory	内存	单位 KB
timeconsume	用时	单位毫秒
student_ID	学习者编号	引用学习者基本信息表中的 student_ID

1.2 数据预处理与指标构建

首先，对原始数据集中存在的缺失值、异常值及数据不一致等噪声信息进行了系统清洗。在清洗过程中发现，部分提交记录的 class 字段取值异常，表现为字段值为 class，而非规范 Class1 至 Class15.

针对该问题，本文通过解析提交文件名推断其所属班级信息，例如由文件名 SubmitRecord-Class1.csv 可确定其班级为 Class1, 并据此对异常取值进行自动替换。该异常共涉及 6 条记录，修复后分别分布于 Class1（2 条）、Class7（1 条）、Class8（2 条）和 Class15（1 条）。

此外，还发现 Class10 的提交记录中存在一名学生 ID(44c7cf3881ae07f7fb3eD)在学生信息表 Data_StudentInfo.csv 中无法匹配的问题。经核查确认，该 ID 为录入错误，其正确形式应为 44c7cf3881ae07f7fb3e. 根据学生信息表，该学生性别为女性，年龄 24 岁，专业为 J23517. 最终对相关提交记录中的错误 ID 进行了统一修正，共修复 1 条记录。

1.3 统一指标构建

修正了噪点信息后。为了让数据更加契合我们数据可视化的实现目标，我们对数据进行了处理。

我们将编程语言、内存等不属于我们主要分析的数据去除，将时间、答题状态、答题分数等数据，整理为“**题目掌握程度**”，以便我们进行后续分析。题目掌握程度的计算公式如下：

第一部分：基础得分

设第一次完全正确提交之前的提交次数为n，所有完全正确提交使用的方法数为m，则基础得分为：

$$base_score = \begin{cases} 1+0.1(m-1), & n=0 \\ \dfrac{1+0.1(m-1)}{1+\mathrm{e}^{a(n-b)}}, & n>0 \end{cases} \tag{1}$$

其中a表示衰减系数，b表示当$m=1$时使$base_score$为0.5的最大非完全正确提交次数，$0.1(m-1)$表示当使用多种方法的奖励。这里我们采用$a=0.4, b=5$.

第二部分：复习增益系数

记第i次正确提交的时间戳为$t_i(i=1,2,\cdots k)$，则复习增益系数为:

$$f_{bonus} = \prod_{i=1}^{k-1} 1 + bonus(t_i, t_{i+1}) \tag{2}$$

其中

$$bonus(t_i,t_j) = \begin{cases} 0, & |t_j - t_i| < 3600\times 24 \\ 0.2\mathrm{e}^{-0.1\left|\frac{|t_j-t_i|}{24\times 3600}-7\right|}, & |t_j-t_i| \geqslant 3600\times 24 \end{cases} \tag{3}$$

第三部分：再错惩罚系数

对于所有部分正确提交、完全错误提交、提交时错误（设其时间戳为t_i），如果在此之前存在一次完全正确提交记录（设其最近一次时间戳为t_i^*），则惩罚系数:

$$f_{penal} = \prod_i 1 - \alpha_i \cdot penal(t_i, t_i^*) \tag{4}$$

其中

$$penal(t_i,t_i^*) = \begin{cases} 0, & |t_i - t_i^*| < 3600\times 24 \\ \mathrm{e}^{-0.2\left|\frac{|t_i-t_i^*|}{24\times 3600}-1\right|}, & |t_i-t_i^*| \geqslant 3600\times 24 \end{cases} \tag{5}$$

部分正确提交、完全错误提交、提交时错误的α值，我们分别取0.05, 0.1, 0.01.

最终结果

单个学生对于单个题目的掌握程度

$$M = \min(1, M_{base}\cdot f_{bonus}\cdot f_{penal}) \tag{6}$$

并由此可以算出单个学生、班级所有学生、机构所有学生对于单个题目、单个子知识点、单个知识点、全部知识点的掌握程度，计算方法再次不一一列举。

最终我们得到一份 `proficiency.csv` 数据，包含序号，班级，学生ID，知识点，子知识点，题目编号，掌握程度的数据。

二、分析目标

2.1 总体目标

本项目旨在基于学习者编程答题行为数据，构建并分析反映学习者对知识点掌握程度的量化指标，通过可视化与可视分析方法，**从知识点掌握、题目难度、练习情况等多个层面揭示个体和班级学习过程中的行为特征与学习效果差异**，为学习行为理解与教学决策提供支持。

2.2 具体目标

围绕构建的“题目掌握程度”指标，项目重点关注以下几个方面的分析目标：

1. 知识点，子知识点，具体题目层面的整体掌握分析
2. 班级层面的学习情况差异分析
3. 学习者个体层面的学习情况分析

2.3 可视化目标

在上述分析目标基础上，本项目通过可视化手段实现以下目标：

1. 支持多维度的对比分析与筛选交互
2. 辅助用户快速发现学习过程中的异常模式、共性规律与个体差异。
3. 以直观方式展示学习者掌握程度的时序演化过程

三、可视化设计与展示

3.1 总览图

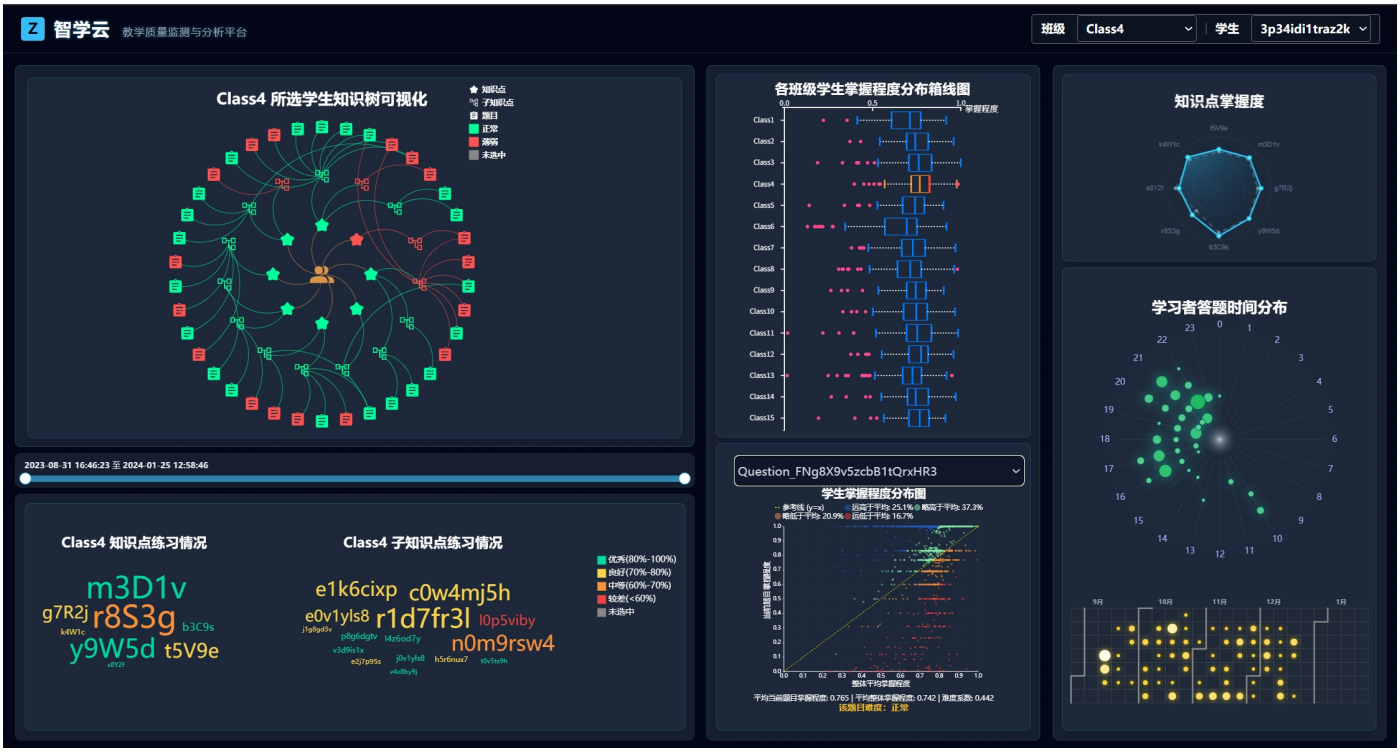


图 1　可视化视图概览

如图 1 所示，教学管理者可视化面板是面向管理者用户，将学生学习情况从左到右分为三个维度。这三部分以班级模块为轴线展开，联动年级、个人，可以有效实现整体教学进度管理与个性化定制教学。

知识树构成面板主入口，联系起左右两部分。不选择班级和学生时，知识树会展示“知识点—子知识点—题目”三级知识层次，给教学管理提供知识体系框架，对数据进行整体感知。

在选择班级后，知识树会展现该班级对各知识点的掌握程度，同时知识点词云、箱线图协同变化，针对有问题的知识点，我们首先锁定知识点词云，判断是否是练习过少导致的，如果总体练习次数较多，我们可以滑动时间条，观察其是否经常练习还是仅集中于一个时间段练习。

如果不是练习方面的原因，我们可以转向看板箱线图，通过观察均线我们可以知道该班级在不同班级中的表现水平，从而理解这是个别班级的教学问题，还是年级整体问题（可能是题目出得太难）。同时如果是题目问题，我们点击知识树中的相关题目，学生掌握程度分布图会协同变化，展示是否是题目问题。

同时，在发现知识点问题时，作为教学管理者，我们也会关心个体学习情况，通过选择学生，知识树展现该生薄弱点具体情况，我们可以转向雷达图，学生—班级平均分之间的对比更直观地展现学生的知识点情况以及差距大小。这种学习问题很可能和学习习惯密切相关，如熬夜刷题、学期末赶 deadline 等，因此我们从一天、一学期两个角度对学生学习习惯画像进行刻画。

总结来说，我们的界面设计使得年级侧的分析与学生侧的分析能够有机联动，如图 2 所示。

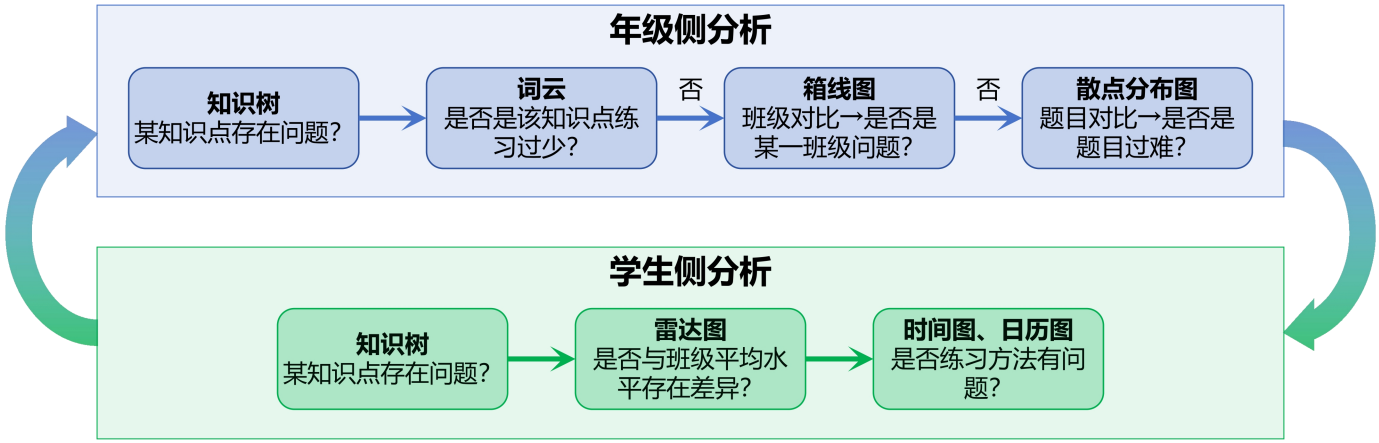


图 2　年级侧分析与学生侧分析有机联动示意

3.2 知识树可视化部分

如图 3 所示，当我们选中特定班级时，知识树会展示该班级所有知识点、子知识点和题目的掌握情况，其中绿色表示正常，即该班级对于该知识点、子知识点或题目的掌握程度高于机构全体学生的平均值，相反地红色表示“薄弱”的知识点、子知识点或题目。

当选择了该班级的特定学生，我们也能够展示该学生所有知识点、子知识点和题目的掌握情况。对于一个学生，我们认定一个知识点、子知识点或题目为“薄弱”的，当且仅当该学生对于该知识点、子知识点或题目的掌握程度低于全班学生的平均值。

为了展示题库中知识点、子知识点和题目的关系，我们添加了以下交互功能：当点击一个知识点时，其下属的子知识点和题目维持原先颜色不变，其余图标变成灰色，如图 4 所示。当点击一个子知识点时，其所属的知识点和下属的题目维持原先颜色不变，其余图标变成灰色，如图 5 所示。当点击一个题目时，其所属的知识点和子知识点维持原先颜色不变，其余图标变成灰色，如图 6、图 7 所示，我们注意到部分题目属于多个子知识点。当点击中间人形图标时，知识树将恢复至图 3 所示的状态。

该部分与课堂教授的“层次数据可视化”部分紧密关联，利用树形结构生动展示了知识点、子知识点和题目的相互关系。

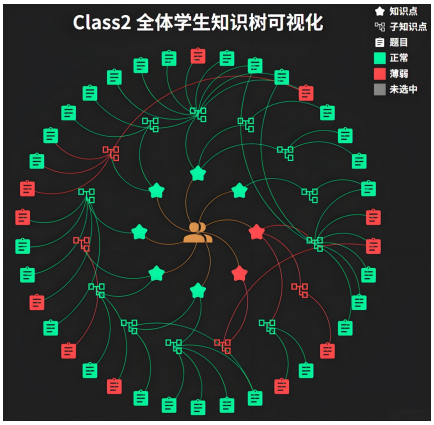


图 3　选中 Class 2 的知识树部分

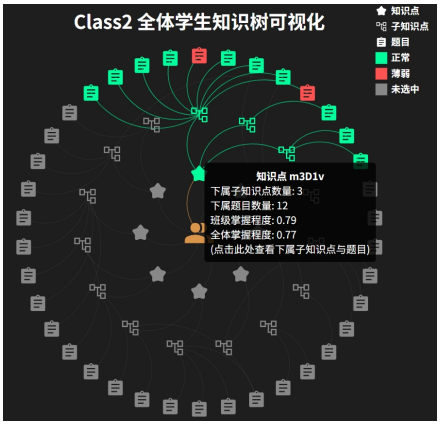


图 4　点击知识点后的状态

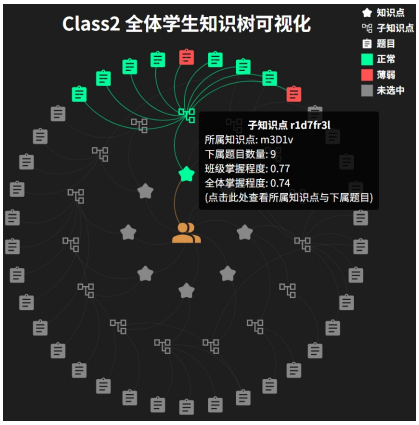


图 5　点击子知识点后的状态

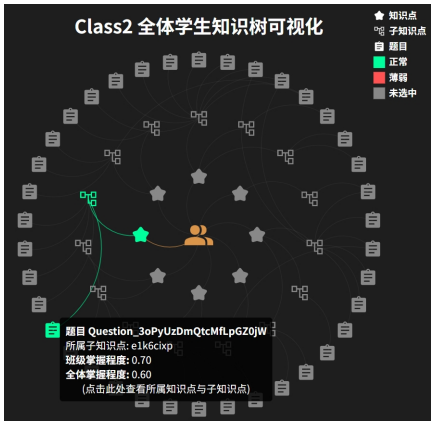


图 6　点击题目后的状态(单子知识点的情况)

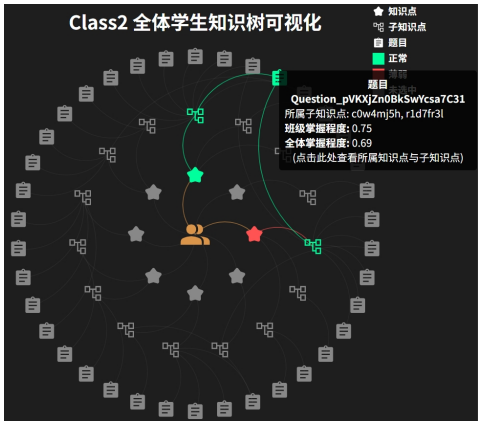


图 7　点击题目后的状态(多子知识点的情况)

3.3 练习情况词云可视化部分

如图 8 所示，我们采用时间滑动条和词云的形式，可视化展示不同时间段一个班级的练习情况。

我们设计的时间滑动条功能强大，不仅两端可以调节，当鼠标点击选择区域时，还可以拖动整个滑动条以实现等时长分析，如图 9 所示。当我们改变时间滑动条状态时，下方的词云也会同时改变。

对于词云部分，我们始终以该班级总时间段内知识点练习次数的最大值映射到文本显示的最大值，这样，无论我们选择哪一个时间段，无论我们关注知识点还是子知识点，文本大小始终与该时间段内对于该知识点或子知识点的练习次数成正比关系。我们根据该班级对于该知识点的掌握程度，将其分为优秀、良好、中等、较差四个等级，并以此分类为文本配色。由于我们始终选择同一个随机数种子，当所选时间段变化时，如果该知识点或子知识点的练习次数占比变化不大，其位置一般变化也不大，这有利于我们持续关注一个知识点或子知识点。

为了更好凸显特定的知识点和子知识点，并且突出知识点与子知识点的从属关系，我们在该部分同样采取了点击高亮的形式。具体来说，当我们点击知识点区域的文本时，其本身及其下属子知识点维持原先颜色不变，其余文本变成灰色，如图 10 所示；当我们点击子知识点区域的文本时，其本身及其所属知识点维持原先颜色不变，其余文本变成灰色，如图 11 所示；当我们再次点击高亮文本，即可恢复成初始状态。

该部分与课堂教授的“文本（内容和关联）数据可视化”“时间数据可视化”密切相关，较好地将三者的特点融合在一起。

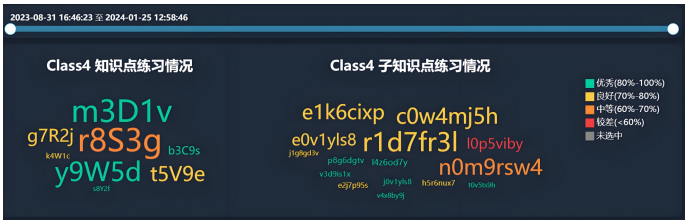


图 8　选择 Class4 后的词云



图 9　选择特定时间段后的词云



图 10　点击一个知识点后的词云



图 11　点击一个子知识点后的词云

3.4 掌握程度分布箱线图部分

箱线图在整个界面中的作用类似于字典的索引，它可以帮助使用者去关注特殊的班级（分布情况与其他班级有明显差异的班级），或者特殊的学生（异常点表示的学生），如图 12 所示。对于一个箱线图，我们可以选中其异常点（附带学生信息）、上下极值、上下四分位数、中位数，并生成参考线用于比较，如图 13 所示。在选中特定班级后，该班级对应的箱线图颜色变成橙色。选中特定学生后，在对应班级的箱线图中会展示该学生在该班级的排名大致分布，如图 14 所示。

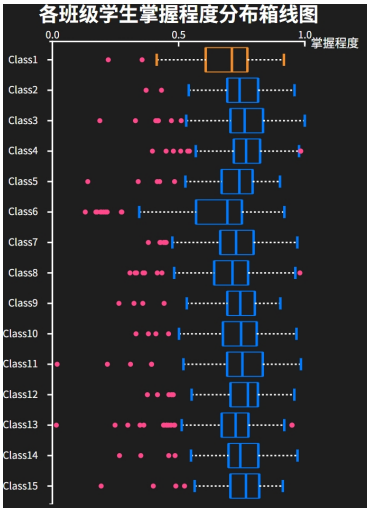


图 12　选择 Class 1 的箱线图

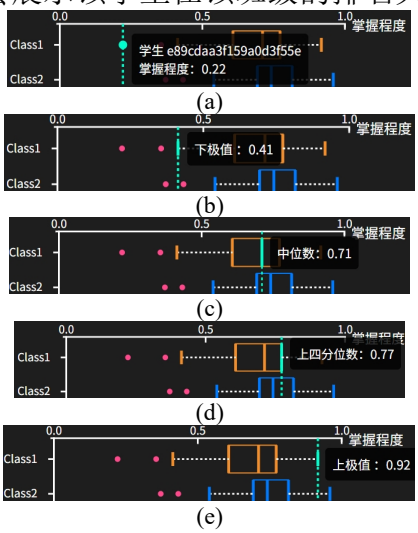


图 13　箱线图中若干可选中的部分

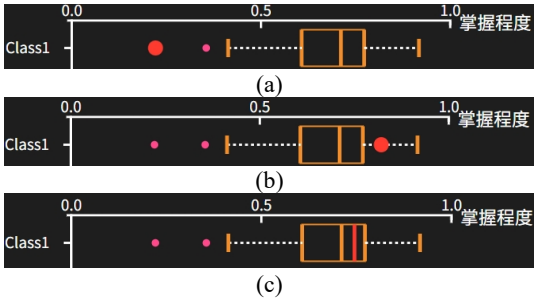


图 14　选中学生后的若干可能显示

3.5 知识掌握度雷达图部分

知识掌握程度雷达图用于对学习者的知识结构进行精细化画像，如图 15 所示。图中青色光晕区域代表当前学生的个人能力边界，而灰色虚线则是班级的平均水平。我们还实现了径向渐变填充效果，这种设计能让教师一目了然地看到学生是“全面发展型”（饱满的多边形）还是“偏科型”（尖锐的多边形），从而实现精准的教学干预。

如图 16 所示。在选中特定知识点后，我们用提示框更清晰地展示某一知识点在该班级的平均掌握程度和该生的掌握程度，极大地提高了实用性。

3.6 学习习惯时钟图部分

学习习惯时钟图将线性时间卷曲，利用极坐标展示了学生在每天 24 小时内的活跃规律，如图 17 所示。我们可以清晰地看到该同学活跃时间相对均匀地分布在一天的学习时间（绿色高亮区域），呈现出典型的持续型学习者模式。

如图 18 所示。在鼠标悬停（Hover）在节点上时，会触发 Tooltip 显示具体的“时段”与“提交次数”，支持用户探索细节数据。

为了保持美观的同时不致数据失真，我们修改了节点轻触放大的设置，改为仅高亮和 Hover 显示。



图 15　点击知识点前的状态



图 16　点击知识点后的状态

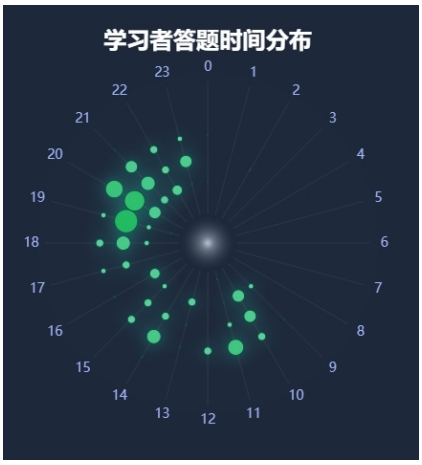


图 17　点击节点前的状态

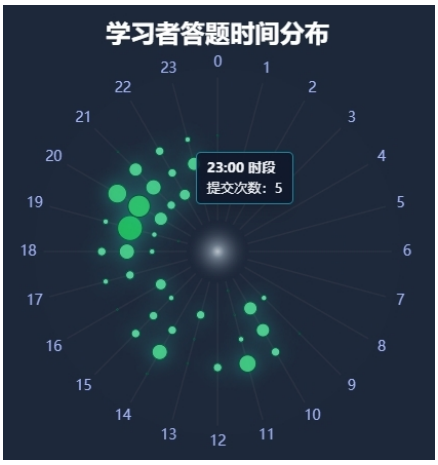


图 18　点击节点后的状态

3.7 学习习惯日历图部分

日历热力图以时间轴为基础，通过黄色气泡的大小映射每日的工作量，如图 19 所示。图表中清晰的月份分割线与网格背景，帮助教师或学生本人快速回顾整个学期的努力轨迹，识别出高强度的“刷题周”与低活跃的“休整期”。

如图 20 所示。学习习惯日历图同样支持 Hover 显示，当鼠标悬停（Hover）在节点上时，会触发 Tooltip 显示具体的“日期”与“提交次数”，支持用户探索细节数据。

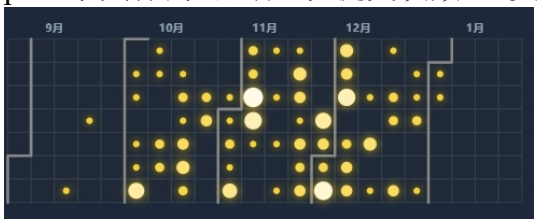


图 19　点击节点前的状态

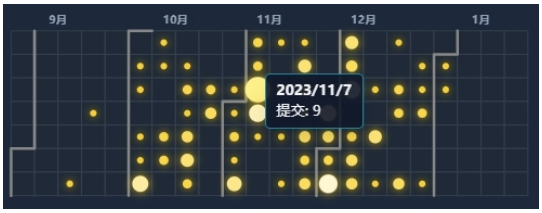


图 20　点击节点后的状态

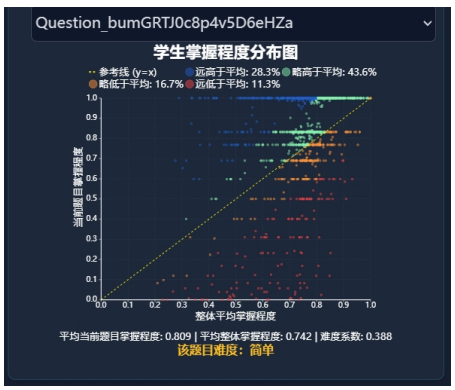


图 21　学生掌握程度分布图

3.8 学生掌握程度分布图

学生掌握程度分布图用于查询题目设置难度。该图是以学生对所有题目整体平均掌握程度为横轴，对当前题目掌握程度为纵轴构建的散点图。利用横纵轴差值将学生对某题的掌握情况分为 4 组（分段

区间为-0.2, 0, 0.2），并通过公式计算得出该题目的难度系数，以此对题目难度进行区分。如图 21 所示，题目可通过选择框手动选择，也可以通过点击知识树题目部分进行联动选择。

四、分析与发现

我们以 Class4 为例，我们在选择框中选择 Class4，如图 22 所示，我们发现 Class4 整体水平不错，但是知识点 r8S3g 是存在显著问题的。

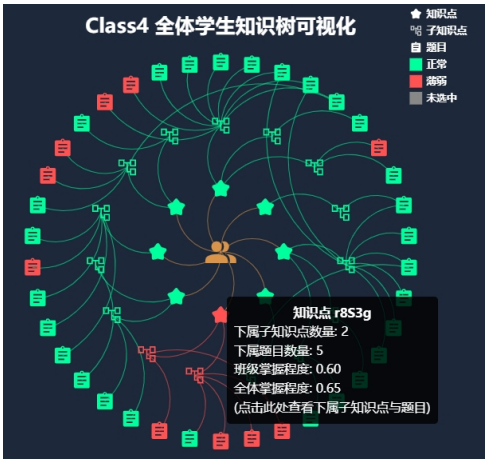


图 22　Class4 全体学生知识树



图 23　知识点 r8S3g 在整个时间段上的练习情况

针对该知识点，我们跳转到知识点联系情况词云。如图 23 所示，通过观察可知，从整个时间段上看，知识点 r8S3g 是训练主体，不应该出现很大的知识漏洞，然而我们选取一个月的区间进行观察，发现该知识点前期训练较多而后期复习不足，如图 24、图 25 所示。或许该班级的**授课教师需要调整自己的教学模式，不仅要注重平时的联系，也要加强后期的巩固**。



图 24　知识点 r8S3g 在前期的练习情况



图 25　知识点 r8S3g 在中后期的练习情况

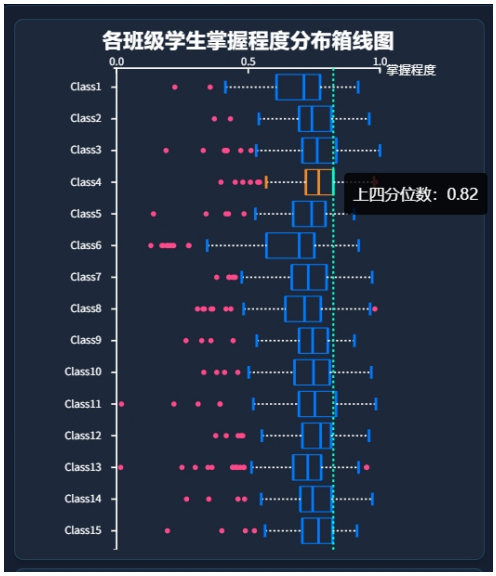
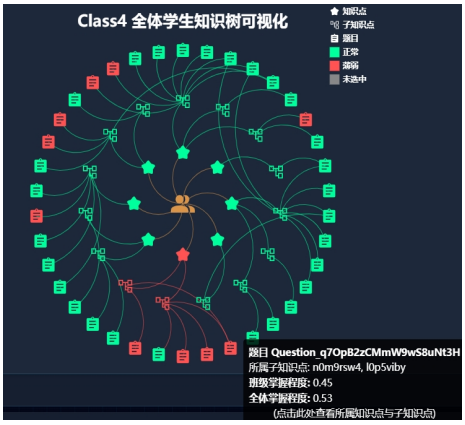


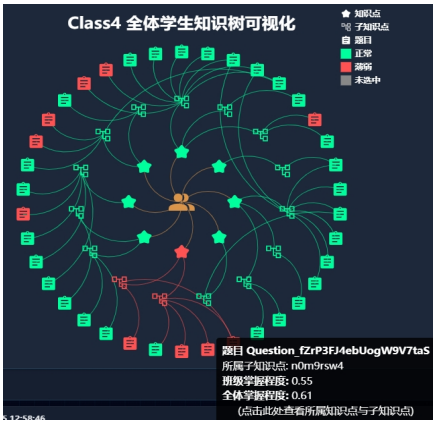
图 26　各班级学生掌握程度箱线图

如图 26 所示，使用箱线图对比各个班级，我们可以看到 Class4 的整体水平在年级中也是相对靠前的，说明可能并不是该班级的教学出了问题。那么我们则需要思考，是否是该知识点下题目本身难度较大，间接导致了 Class4 的学生对于该知识点的练习情况不佳。

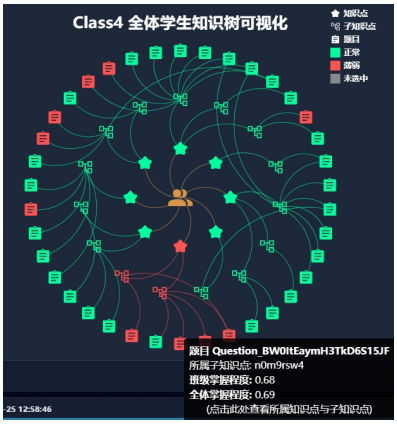
我们依次点击知识树中知识点 r8S3g 下薄弱的三道题目，通过知识树和掌握程度散点分布图交互来使用查看学生掌握情况。如图 27、图 28、图 29 所示，我们发现在有问题的三道题目中，两道题都难度为复杂，这可能可以解释 Class4 这个整体水平相对靠前的班级，在对于该知识点总体上练习次数并不少的情况下，却出现了知识点练习情况不佳的情况。为了解决这个问题，**题库的管理者可能需要重新设计该知识点下的习题，使得练习情况能和掌握程度相匹配**。



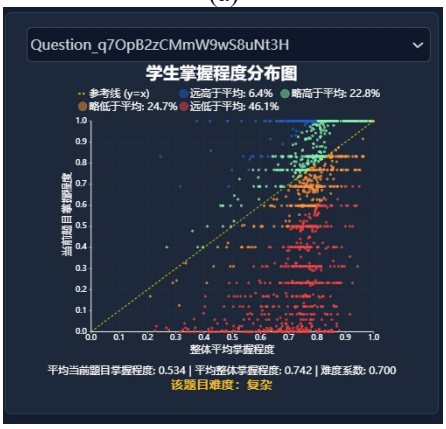
(a)



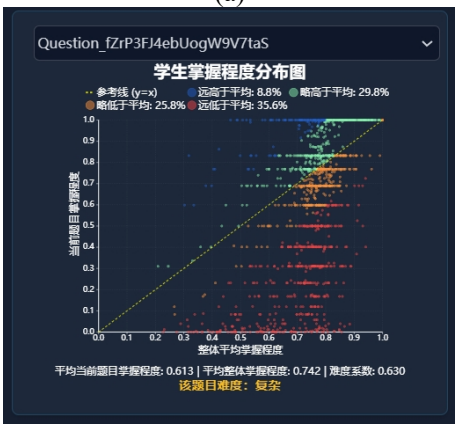
(a)



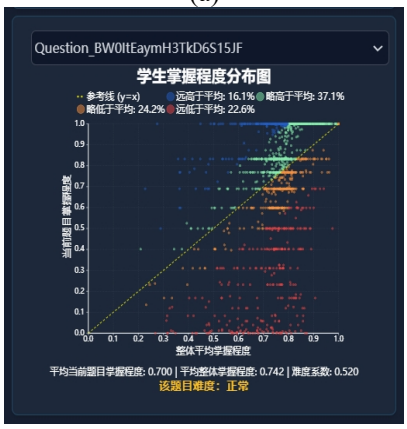
(a)



(b)



(b)



(b)

图 27　题目 q7OpB2zCMmW9wS8uNt3H　　图 28　题目 fZrP3FJ4ebUogW9V7taS　　图 29　题目 BWoltEaymH3TkD6S15JF

除了解析宏观教学问题，我们的可视化系统同样适用于个性化教学诊断。通过箱线图，我们可以通过箱线图查看班级中一些偏离均值的个体，例如我们点击 Class4 明显低于平均值的最后一位同学 90f3fbedfce50f644011，如图 30 所示。点击后，我们的知识树将会展示该学生对于各个知识点、子知识点和题目的掌握情况，如图 31 所示，我们发现该同学有多个知识点存在薄弱情况。

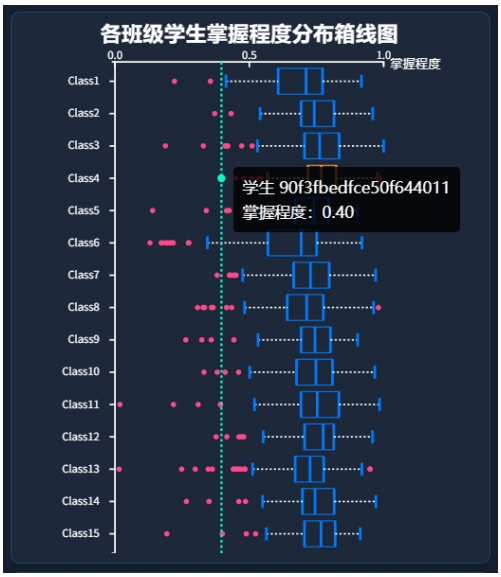


图 30　学生 90f3fbedfce50f644011 在班级的大致位次

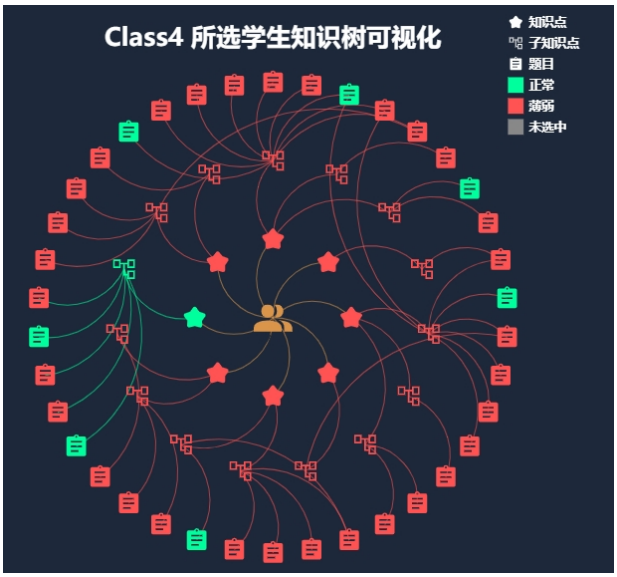


图 31　学生 90f3fbedfce50f644011 的知识树

我们跳转到学习者画像分析界面，通过如图 32 所示的学生知识点掌握度雷达图，我们更清晰的看出这个学生多知识点低于平均水平，并有两个知识点未进行过练习。从图 33 的日历图和图 34 的时间图可以看出，这个学生练习习惯比较不规律，存在熬夜学习、期末突击的问题，这有可能是导致他成绩在 Class4 中相对落后的原因。针对该学生的学习情况，我们可以建议该学生**注重知识点的全面练习，同时调整自己的学习习惯，做到知识点及时掌握，期末加强巩固**。同时对于 Class4 的教师，也可以根据该学生的学习情况**制订个性化的教学方案**，帮助该同学提高成绩。



图 32　学生 90f3fbedfce50f644011 知识点掌握程度雷达图

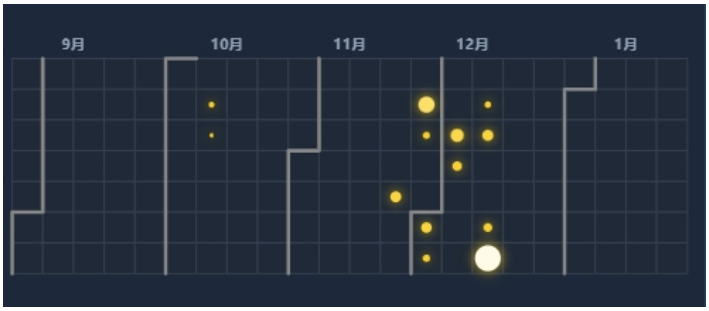


图 33 学习习惯日历图

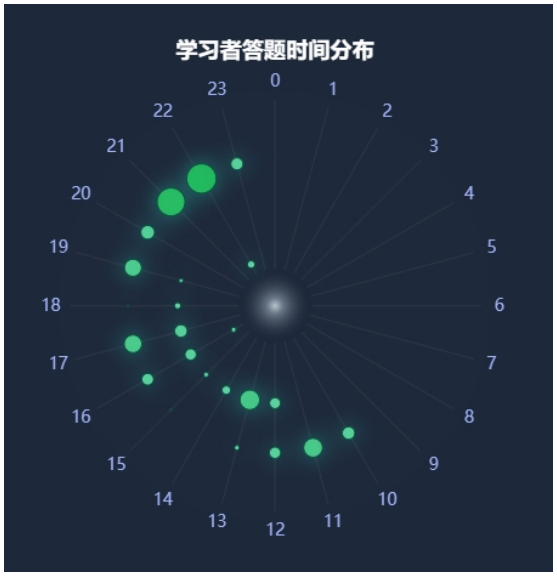


图 34　学习习惯时钟图

五、总结

本项目围绕学习者编程答题行为数据，构建了以“题目掌握程度”为核心的量化指标，并在此基础上设计并实现了一套面向教学管理者的可视分析系统。通过对学习者个体、班级整体以及知识点结构的多层次分析，系统能够较为全面地反映学习过程中的掌握情况、行为差异与潜在问题。

在数据层面，项目对原始日志数据进行了针对性预处理，**将离散且含有噪声的提交记录转化为连续、可比较的掌握程度指标**，使得学习效果的变化能够被长期追踪和分析。

在分析层面，系统通过知识树、词云、箱线图等多种可视化手段，支持从“知识点—班级—题目—学生”的逐层下钻分析，**既能够帮助教学管理者发现宏观层面的教学问题，也能够辅助定位到具体题目或个体学生的薄弱环节**。

在个性化分析方面，项目进一步结合雷达图、学习习惯时钟图与日历图，对学习者的知识结构与学习行为模式进行刻画，使分析不仅停留在“结果”，而是能够追溯到“过程”，为个性化教学干预和学习习惯优化提供依据。通过真实分析案例验证，系统能够有效支持教学决策与学习诊断，体现了可视分析在教育数据场景中的实际价值。

本项目的制作**与课堂教学内容紧密结合**。项目使用了颜色、大小、位置等多种可视映射方法；知识树部分将对层次数据可视化；添加时间滑动条的词云，不仅同时实现文本内容和关系的可视化，也对一个时变数据进行可视化；不同图表之间的交互，也增强了系统的可操作性。

当然，本项目仍存在一定的改进空间。例如，掌握程度模型中的参数主要基于经验设定，未来可结合更多实验或真实教学反馈进行优化；此外，当前分析主要基于历史数据，后续可进一步探索实时分析或预测性分析的可能性。

总体而言，本项目较好地完成了课程目标，将数据处理、指标建模与可视化设计有机结合，不仅加深了小组成员对数据可视化方法与可视分析流程的理解，也展示了可视化技术在复杂教育数据分析场景中的应用潜力。